

POLITECHNIKA POZNAŃSKA

WYDZIAŁ INFORMATYKI I TELEKOMUNIKACJI

INSTYTUT INFORMATYKI

ZAKŁAD UCZENIA MASZYNOWEGO



RAPORT ZE STUDIUM PRZYPADKU

SYSTEMU UCZĄCE SIĘ

PAWEŁ CHUMSKI, 144392

PAWEŁ.CHUMSKI@STUDENT.PUT.POZNAN.PL

PROWADZĄCY:

DR HAB. INŻ. MACIEJ KOMOSIŃSKI PROF. PP

MACIEJ.KOMOSINSKI@CS.PUT.POZNAN.PL

09-06-2023



Spis treści

Wstęp	3
1 Wine Quality Dataset	3
1.1 Opis danych	3
1.2 Implementacja	3
1 1 Podstawowe informacje o danych	3
1 2 Eksploracja danych	4
1 3 Korelacje	12
1 4 Trenowanie modeli	17
1.3 Podsumowanie	23

WSTĘP

Celem zadania było przeprowadzenie analizy samodzielnie wybranego zbioru danych oraz zastosowanie różnych algorytmów uczenia maszynowego w celu odkrycia interesujących zależności i właściwości w tym zbiorze. Wybór zbioru danych został oparty na własnych źródłach, repozytoriach lub stronach internetowych. Motywacją do wyboru konkretnego zbioru danych została przedstawiona, a także wskazano atrybut decyzyjny i warunkowe. Przedstawiono konkretne przypadki z interpretacją wartości atrybutów oraz oceniono modele za pomocą odpowiednich wskaźników.

WINE QUALITY DATASET

1.1 OPIS DANYCH

Zdecydowałem się na zbiór Wine Quality Dataset. Ten zbiór danych dotyczy czerwonych odmian portugalskiego wina "Vinho Verde". Zbiór danych opisuje ilość różnych substancji chemicznych obecnych w winie i ich wpływ na jego jakość. Wybrałem ten zbiór danych, ponieważ zaintrygowała mnie analiza danych na podstawie cech fizykochemicznych jakości wina.

Atrybutem decyzyjnym w tym przypadku jest "quality"(jakość wina). Wartość tego atrybutu będzie określana na podstawie innych cech fizykochemicznych wina, czyli atrybutów warunkowych. Atrybut ten przyjmuje wartości od 0 do 10.

Atrybuty warunkowe są to:

- 1 - stała kwasowość (fixed acidity)
- 2 - lotna kwasowość (volatile acidity)
- 3 - kwas cytrynowy (citric acid)
- 4 - resztkowy cukier (residual sugar)
- 5 - chlorki (chlorides)
- 6 - wolny dwutlenek siarki (free sulfur dioxide)
- 7 - całkowity dwutlenek siarki (total sulfur dioxide)
- 8 - gęstość (density)
- 9 - pH
- 10 - siarczany (sulphates)
- 11 - alkohol (alcohol)

Trudności przy analizie tego zbioru danych to brak równoważności klas, niewielka liczba próbek i wysoka liczba cech. Brak równoważności klas może wpływać na skuteczność modelu, a niewielka liczba próbek może prowadzić do przeuczenia. Dodatkowo, duża liczba cech może utrudnić wybór odpowiednich cech dla modelu.

1.2 IMPLEMENTACJA

1 PODSTAWOWE INFORMACJE O DANYCH

Na samym początku zainicjowano odpowiednie importy oraz załadowano dane. Następnie je skopowano i sprawdzono, czy nie posiadają braków.

Tab. 1. Sprawdzenie braków w danych

Atrybut	Wartość
fixed acidity	0
volatile acidity	0
citric acid	0
residual sugar	0
chlorides	0
free sulfur dioxide	0
total sulfur dioxide	0
density	0
pH	0
sulphates	0
alcohol	0
quality	0

Jak widać na powyższej tabeli, wszystkie wartości zwróciły wartość 0, więc nie występują ubytki w danych. Następnie sprawdzono inne zależności w danych, jak liczba próbek, średnią wartość, odchylenie standardowe itd. Wyniki zostały przedstawione w poniższej tabeli.


Tab. 2. Tabela danych

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
count	1143	1143	1143	1143	1143	1143	1143	1143	1143	1143	1143	1143
mean	8.3	0.53	0.27	2.53	0.087	15.62	45.91	0.997	3.31	0.66	10.4	5.66
std	1.75	0.18	0.197	1.36	0.05	10.25	32.78	0.002	0.16	0.17	1.08	0.81
min	4.6	0.12	0.0	0.9	0.012	1.0	6.0	0.99	2.74	0.33	8.4	3.0
25%	7.1	0.39	0.09	1.9	0.07	7.0	21.0	0.996	3.21	0.55	9.5	5.0
50%	7.9	0.52	0.25	2.2	0.079	13.0	37.0	1.0	3.31	0.62	10.2	6.0
75%	9.1	0.64	0.42	2.6	0.09	21.0	61.0	1.0	3.4	0.73	11.1	6.0
max	15.9	1.58	1.0	15.5	0.61	68.0	289.0	1.01	4.01	2.0	14.9	8.0


Można tutaj zauważyć, że dane mają różne skale, więc ważne będzie przeprowadzenie normalizacji. Również dowiadujemy się, że każdy atrybut ma taką samą liczbę próbek - 1143. Ta informacja jest również przydatna, ponieważ jakość zawsze reprezentowana przez wszystkie atrybuty. Poza tym jakość określana jest z przedziału 3 - 5, co może wpłynąć na wyniki klasyfikatorów.

2 EKSPLORACJA DANYCH


Następnie sprawdzono liczbę wystąpień poszczególnych wartości za pomocą Count Plot. Wyniki prezentują się poniżej.




Rys. 1. Count Plot dla atrybutu *fixed acidity*




Rys. 2. Count Plot dla atrybutu volatile acidity




Rys. 3. Count Plot dla atrybutu citric acid




Rys. 4. Count Plot dla atrybutu residual sugar




Rys. 5. Count Plot dla atrybutu chlorides




Rys. 6. Count Plot dla atrybutu free sulfur dioxide




Rys. 7. Count Plot dla atrybutu total sulfur dioxide




Rys. 8. Count Plot dla atrybutu density



Rys. 9. Count Plot dla atrybutu pH




Rys. 10. Count Plot dla atrybutu *sulphates*




Rys. 11. Count Plot dla atrybutu *alcohol*


Wykres Count Plot przedstawia liczbę wystąpień poszczególnych wartości, co daje ogólny obraz rozkładu. Jednak może być trudno zinterpretować tę liczbę w kontekście całego rozkładu danych, ponieważ widać tutaj, że u każdego atrybutu liczba wystąpień poszczególnych wartości jest przeróżna. Warto zatem skorzystać z wykresu Density Plot, który pozwala na zobrazowanie gęstości rozkładu prawdopodobieństwa lub gęstości wystąpień danych na osi Y. To daje bardziej szczegółową informację o tym, jak wartości są rozmieszczone wokół osi X i jak prawdopodobieństwo wystąpienia danej wartości zmienia się w zależności od jej położenia. Dzięki temu można łatwiej zidentyfikować obszary większej koncentracji wartości, wykryć wzorce, a także ocenić symetryczność lub skośność rozkładu danych. Wykres Density Plot uzupełni zatem informacje zawarte na powyższych wykresach i dostarcza dodatkowych wglądów w rozkład danych. Poniżej znajdują się wykresy Density Plot.




Rys. 12. Count Density dla atrybutu fixed acidity




Rys. 13. Count Density dla atrybutu volatile acidity




Rys. 14. Count Density dla atrybutu citric acid




Rys. 15. Count Density dla atrybutu residual sugar




Rys. 16. Count Density dla atrybutu chlorides




Rys. 17. Count Density dla atrybutu free sulfur dioxide




Rys. 18. Count Density dla atrybutu total sulfur dioxide




Rys. 19. Count Density dla atrybutu density



Rys. 20. Count Density dla atrybutu pH




Rys. 21. Count Density dla atrybutu sulphates



Rys. 22. Count Density dla atrybutu alcohol

Większość danych w tym zbiorze wykazuje skośny rozkład (ujemny lub dodatni) zamiast symetrycznego. Skośność oznacza, że dane nie są równomiernie rozłożone względem średniej. W przypadku występowania wartości odstających, które znacząco różnią się od reszty danych, rozkład staje się bardziej skośny. Zastąpienie wartości odstających przez medianę, która jest bardziej odporna na wpływ ekstremalnych wartości, może pomóc w przywróceniu symetrii w rozkładzie danych. Poprawa symetrii rozkładu może ułatwić analizę i interpretację danych, eliminując wpływ ekstremalnych wartości.

Następnie sprawdzono jak wygląda sprawa z atrybutem decyzyjnym, co pokazuje nam poniższy wykres.




Rys. 23. Rozkład wartości w atybutie quality

Jak widać dane są mocno niezbalansowane i przeważają wartości 5 oraz 6, które znacznie dominują.


3 KORELACJE

Następnie sprawdzono macierz korelacji i jak poszczególne atrybuty warunkowe korelują ze sobą.




Rys. 24. Macierz korelacji pomiędzy poszczególnymi atrybutami

Można zauważyć, że niektóre wartości korelują ze sobą jak chociażby citric acid z fixed acidity, ale są też atrybuty, które mają współczynnik korelacji ze sobą bardzo niski. Na przykład pH oraz fixed acidity. Poza tym nic więcej nie mówi ten wykres, więc sprawdzono rozkład korelacji względem quality i które atrybuty wpływają najbardziej na jakość.




Rys. 25. Korelacja pomiędzy quality, a poszczególnymi atrybutami warunkowymi


Można zauważyć, że największy wpływ na jakość ma alcohol, sulphates, citric acid, fixed acidity, a najmniejszy volatile acidity. Jednak te atrybuty, które mają wpływ na jakość, mogą mieć na nią wpływ zarówno pozytywny jak i negatywny. Dlatego warto sprawdzić, jak poszczególne atrybuty wpływają osobno na jakość, co prezentują wykresy poniżej.




Rys. 26. Korelacja atrybutu quality z atrybutem fixed acidity




Rys. 27. Korelacja atrybutu quality z atrybutem volatile acidity




Rys. 28. Korelacja atrybutu quality z atrybutem citric acid




Rys. 29. Korelacja atrybutu quality z atrybutem residual sugar




Rys. 30. Korelacja atrybutu quality z atrybutem chlorides




Rys. 31. Korelacja atrybutu quality z atrybutem free sulfur dioxide




Rys. 32. Korelacja atrybutu quality z atrybutem total sulfur dioxide




Rys. 33. Korelacja atrybutu quality z atrybutem density



Rys. 34. Korelacja atrybutu quality z atrybutem pH



Rys. 35. Korelacja atrybutu quality z atrybutem sulphates




Rys. 36. Korelacja atrybutu quality z atrybutem alcohol

Możemy zauważyć, że niektóre wartości poszczególnych atrybutów wpływają na jakość. Dla atrybutu volatile acidity można zauważyć, że im mniejsze stężenie tego atrybutu, to lepsza jakość wina. Taka sama sytuacja ma miejsce z atrybutem density oraz pH. Przeciwnie natomiast atrybut alcohol oraz sulphates, gdzie im wyższe ich stężenie tym lepsza jakość wina. W atrybucie free sulfur dioxide, możemy zauważyć, że przy powyżej pewnego stężenia, nie otrzymamy niskiej jakości wina. Natomiast w atrybucie chlorides jest odwrotnie i tam przy większym stężeniu z reguły otrzymamy gorszy jakościowo trunek. Większość atrybutów jest zbilansowana. Po dowiedzeniu się kilku ciekawych i ważnych zależności, możemy przejść do wytrenowania modelu.


4 TRENOWANIE MODELI

Najpierw rozpocząłem od oversamplingu, który wykonałem przy użyciu, RandomOverSampler.



Rys. 37. Rozkład wartości w atrybucie quality po oversamplingu

Następnie znormalizowano dane i podzielone na dwa zbiory. Użyto 6 klasyfikatorów do porównania wyników. Użyto DecisionTreeClassifier, RandomForestClassifier, KNeighborsClassifier, SVC, LogisticRegression, GradientBoostingClassifier. Do oceny użyto 'Accuracy', 'F1-score', 'Precision', 'Recall', 'Cross-Validation'. Wyniki prezentują się następująco.




Rys. 38. Porównanie wyników dla poszczególnych klasyfikatorów

Tab. 3. Tabela danych

	Accuracy	F1-score	Precision	Recall	Cross-Validation
DecisionTreeClassifier(random_state = 0)	59.090909	36.990236	36.817496	37.594763	85.406219
RandomForestClassifier(random_state = 0)	65.034965	37.923043	35.936362	42.289636	89.227819
KNeighborsClassifier()	47.902098	26.286109	28.309611	26.471732	81.169871
SVC(random_state = 0)	47.552448	26.663681	31.497116	27.589268	75.414905
LogisticRegression(random_state = 0)	37.062937	21.390407	24.685729	24.907782	60.405424
GradientBoostingClassifier(random_state = 0)	57.692308	31.634543	31.641784	32.043577	88.352561

Wyniki wyszły niezbyt zadowalające, najlepsze wyniki osiąga DecisionTreeClassifier, RandomForestClassifier. Za pomocą gridSearcha, sprawdzono najlepsze parametry i sprawdzono jakie teraz wyniki zostaną osiągnięte. Najlepsze parametry uzyskano dla
DecisionTreeClassifier(random_state=0, max_depth=21),
RandomForestClassifier(random_state=0, max_depth=18, n_estimators=250),
KNeighborsClassifier(n_neighbors=5, weights='distance'),
SVC(random_state=0, C=0.9000000000000001, kernel='rbf'),
LogisticRegression(random_state=0, C=0.9000000000000001, solver='saga'),
GradientBoostingClassifier(random_state=0, learning_rate=0.1, max_depth=7, n_estimators=200).




Rys. 39. Porównanie wyników dla poszczególnych klasyfikatorów z najlepszymi parametrami


Tab. 4. Tabela danych

	Accuracy	F1-score	Precision	Recall	Cross-Validation
DecisionTreeClassifier	59.090909	36.990236	36.817496	37.594763	85.4982
RandomForestClassifier	65.384615	38.392601	36.399325	42.702214	89.0894
KNeighborsClassifier	55.244755	29.945729	31.580829	29.724003	86.0047
SVC	47.902098	26.807344	31.640794	28.152100	75.2769
LogisticRegression	37.062937	21.439028	24.685729	25.053603	60.4514
GradientBoostingClassifier	64.335664	29.270138	29.373014	29.920076	90.0097


Wyniki uległy minimalnej poprawie, wręcz kosmetycznej i nie są nadal satysfakcjonujące. Postanowiono zatem usunąć kilka atrybutów, ale najpierw sprawdzono, które atrybuty pozytywnie wpływają na jakość. Wyniki te przedstawiono na poniższych wykresach.




Rys. 40. SelectKBest (f_{classif})




Rys. 41. SelectKBest (χ^2)




Rys. 42. SelectKBest (mutual_info)




Rys. 43. Random Forest



Rys. 44. Logistic Regression




Rys. 45. Decision Tree



Rys. 46. Gradient Boosting

Na podstawie tych danych oraz wcześniejszych zdecydowałem się przeprowadzić analizę uwzględniając tylko poniższe atrybuty: "volatile acidity", "citric acid", "total sulfur dioxide", "sulphates", "alcohol". One najczęściej osiągają na tych wskaźnikach najlepsze wartości i mają największy wpływ. Wyniki tego eksperymentu prezentują się poniżej.



Rys. 47. Porównanie wyników dla poszczególnych klasyfikatorów, po usunięciu większości atrybutów.

Tab. 5. Tabela danych

	Accuracy	F1-score	Precision	Recall	Cross-Validation
DecisionTreeClassifier(random_state = 0)	57.342657	30.585575	31.401924	30.031797	85.313841
RandomForestClassifier(random_state = 0)	63.636364	36.929679	35.355712	40.321527	88.583082
KNeighborsClassifier()	43.706294	23.303466	24.604258	24.038744	80.572594
SVC(random_state = 0)	43.706294	28.879852	48.722333	29.346034	67.542031
LogisticRegression(random_state = 0)	37.062937	24.288075	46.045882	27.433725	51.658880
GradientBoostingClassifier(random_state = 0)	55.244755	32.050716	31.357726	32.958075	86.788071

Widać że wyniki są podobne do modeli trenowanych na wszystkich atrybutach. Trochę wyniki w SVC i LogisticRegression, gdzie poprawie uległ wynik w precision. Podobnie jak wcześniej, tutaj też wyliczono najlepsze parametry. Prezentują się one następująco:

DecisionTreeClassifier(random_state=0, max_depth=14),

RandomForestClassifier(random_state=0, max_depth=16, n_estimators=250),


KNeighborsClassifier(n_neighbors=5, weights='distance'),

SVC(random_state=0, C=0.9000000000000001, kernel='rbf'),

LogisticRegression(random_state=0, C=0.1, solver='newton-cg'),

GradientBoostingClassifier(random_state=0, learning_rate=0.1, max_depth=7, n_estimators=200)

Wyniki prezentują się poniżej.



Rys. 48. Porównanie wyników dla poszczególnych klasyfikatorów z najlepszymi parametrami

Tab. 6. Tabela danych

	Accuracy	F1-score	Precision	Recall	Cross-Validation
DecisionTreeClassifier	55.944056	28.230943	28.538586	28.144591	85.5900
RandomForestClassifier	63.286713	36.988802	35.543193	39.999409	89.0437
KNeighborsClassifier	49.650350	26.137044	27.336386	26.429701	85.2682
SVC	44.405594	29.236255	49.003752	29.715358	67.0355
LogisticRegression	35.314685	23.403684	45.333428	27.260169	52.1652
GradientBoostingClassifier	60.489510	27.996179	28.147462	28.109207	88.9520

Niektóre wyniki się poprawiły, ale co jest zaskakujące część z wyników uległa pogorszeniu. Może to wynikać z tego że parametry, które zostały wyliczone, nie w każdym przypadku były tymi najoptymalniejszymi.

1.3 PODSUMOWANIE

Podsumowując, wykonano analizę jakości wina na podstawie dostępnych atrybutów. Jednocześnie atrybutów warunkowych wpływało na atrybut decyzyjny związany z jakością, który przyjmował wartości od 3 do 8. Na podstawie korelacji atrybutów z atrybutem "quality" stwierdzono, że niektóre atrybuty mają wpływ na jakość wina, takie jak "volatile acidity", "density", "pH", "alcohol" i "sulphates". Następnie przeprowadzono trenowanie modeli klasyfikacji, używając różnych algorytmów i oceniając wyniki za pomocą metryk takich jak "Accuracy", "F1-score", "Precision" i "Recall". W wyniku porównania wyników, stwierdzono, że DecisionTreeClassifier i RandomForestClassifier osiągnęły najlepsze wyniki. Następnie przeprowadzono analizę, wykorzystując tylko wybrane atrybuty, co również nieznacznie poprawiło wyniki, ale nie w pełni satysfakcjonujące. Wybrane modele zostały dalej zoptymalizowane za pomocą gridSearch, ale wyniki nie uległy znaczącej poprawie. Wnioskując, analiza jakości wina za pomocą systemu uczącego jest wyzwaniem, które wymaga dalszych badań i doskonalenia modeli. Możliwe że lepsze wyniki można by osiągnąć, gdyby atrybut decyzyjny quality rozbić tylko na dwie klasy, gdzie ocenilibyśmy jakość tylko za pomocą wyznacznika czy jest dobre, czy nie. Wtedy łatwiej byłoby wyuczyć model i osiągnięto by lepsze rezultaty.